

Misturas de distribuição

Misturas finitas de distribuição

- São adequados na para modelar dados com presença de subgrupos não observáveis;

Misturas finitas de distribuição

- São adequados na para modelar dados com presença de subgrupos não observáveis;
- Podem ser utilizados para agrupamento de observações.

Misturas finitas de distribuição

Definamos uma mistura finita de distribuições da seguinte maneira. Seja Z uma variável aleatória discreta com

$$P(Z = j) = p_j, \quad j = 1, 2, \dots, G.$$

Misturas finitas de distribuição

Definamos uma mistura finita de distribuições da seguinte maneira. Seja Z uma variável aleatória discreta com

$$P(Z = j) = p_j, \quad j = 1, 2, \dots, G.$$

Seja $Y|Z = j, \theta_j$ uma variável aleatória contínua com função densidade de probabilidade $g(y|Z = j, \theta_j)$.

Misturas finitas de distribuição

Definamos uma mistura finita de distribuições da seguinte maneira. Seja Z uma variável aleatória discreta com


$$P(Z = j) = p_j, \quad j = 1, 2, \dots, G.$$

Seja $Y|Z = j, \boldsymbol{\theta}_j$ uma variável aleatória contínua com função densidade de probabilidade $g(y|Z = j, \boldsymbol{\theta}_j)$. É possível mostrar que a densidade marginal de $Y|\boldsymbol{\theta}$ é dada por

$$f(y|\boldsymbol{\theta}) = \sum_{j=1}^G p_j g(y|Z = j, \boldsymbol{\theta}_j),$$

Misturas finitas de distribuição

Dizemos que $Y|\theta$ é uma mistura finita de distribuições com G componentes em que cada componente tem densidade g .



Mistura de regressões t assimétricas

t de Student assimétrica

Dizemos que uma variável aleatória Y tem distribuição t de Student assimétrica quando

$$Y = \mu + X/\sqrt{U}.$$

Em que $X \sim \text{SN}(0, \sigma^2, \lambda)$ (Azzalini, 1985) e $U \sim \text{Gama}(\nu/2, \nu/2)$. Escrevemos $Y \sim \text{ST}(\mu, \sigma^2, \lambda, \nu)$.

t de Student assimétrica

Dizemos que uma variável aleatória Y tem distribuição t de Student assimétrica quando

$$Y = \mu + X/\sqrt{U}.$$

Em que $X \sim \text{SN}(0, \sigma^2, \lambda)$ (Azzalini, 1985) e $U \sim \text{Gama}(\nu/2, \nu/2)$. Escrevemos $Y \sim \text{ST}(\mu, \sigma^2, \lambda, \nu)$. A v.a. Y tem densidade dada por

$$\text{St}(y|\mu, \sigma^2, \lambda, \nu) = 2t(y|\mu, \sigma^2, \nu)T_{\nu+1}\left(z\lambda\sqrt{\frac{\nu+1}{z^2+\nu}}\right),$$

com $z = (y - \mu)/\sigma$.

t de Student assimétrica

Dizemos que uma variável aleatória Y tem distribuição t de Student assimétrica quando

$$Y = \mu + X/\sqrt{U}.$$

Em que $X \sim \text{SN}(0, \sigma^2, \lambda)$ (Azzalini, 1985) e $U \sim \text{Gama}(\nu/2, \nu/2)$. Escrevemos $Y \sim \text{ST}(\mu, \sigma^2, \lambda, \nu)$. A v.a. Y tem densidade dada por

$$\text{St}(y|\mu, \sigma^2, \lambda, \nu) = 2t(y|\mu, \sigma^2, \nu)T_{\nu+1}\left(z\lambda\sqrt{\frac{\nu+1}{z^2+\nu}}\right),$$

com $z = (y - \mu)/\sigma$.

$$\mathbb{E}(Y) = \mu + \Delta\sqrt{\frac{\nu}{\pi}}\frac{\Gamma(\frac{\nu-1}{2})}{\Gamma(\nu/2)}$$

t de Student assimétrica




Figura 1: Função densidade da t assimétrica.

Representação hierárquica

A distribuição t assimétrica admite a seguinte representação hierárquica:

$$\begin{aligned}Y|T = t, U = u &\sim N(\mu + \Delta t, u^{-1}\tau^2); \\T|U = u &\sim N_{(0,\infty)}(0, u^{-1}); \\U &\sim \text{Gama}(\nu/2, \nu/2).\end{aligned}\tag{1}$$

com $\tau^2 = \sigma^2(1 - \delta^2)$, $\Delta = \sigma\delta$ e $\delta = \lambda/\sqrt{1 + \lambda^2}$.

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

- G é o número de componentes na mistura;

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

- G é o número de componentes na mistura;
- $\varepsilon_i | Z_i = j \sim \text{ST}(b\Delta_j, \sigma_j^2, \lambda_j, \nu)$;

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

- G é o número de componentes na mistura;
- $\varepsilon_i | Z_i = j \sim \text{ST}(b\Delta_j, \sigma_j^2, \lambda_j, \nu)$;
- Graus de liberdade (ν) iguais entre as componentes;

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

- G é o número de componentes na mistura;
- $\varepsilon_i | Z_i = j \sim \text{ST}(b\Delta_j, \sigma_j^2, \lambda_j, \nu)$;
- Graus de liberdade (ν) iguais entre as componentes;
- b é tal que $\mathbb{E}[\varepsilon_i | Z_i = j] = 0$.

Mistura de regressões t assimétricas

Seja Y_i a resposta do i -ésimo indivíduo, a este indivíduo considere uma variável latente discreta Z_i tal que, dado $Z_i = j$, Y_i dependa do vetor de covariáveis $\mathbf{x}_i^\top = (1, x_{i1}, \dots, x_{ik})$ conforme

$$Y_i = \mathbf{x}_i^\top \boldsymbol{\beta}_j + \varepsilon_i, \quad j = 1, \dots, G.$$

- G é o número de componentes na mistura;
- $\varepsilon_i | Z_i = j \sim \text{ST}(b\Delta_j, \sigma_j^2, \lambda_j, \nu)$;
- Graus de liberdade (ν) iguais entre as componentes;
- b é tal que $\mathbb{E}[\varepsilon_i | Z_i = j] = 0$.

$$b = -\sqrt{\frac{\nu}{\pi}} \frac{\Gamma(\frac{\nu-1}{2})}{\Gamma(\nu/2)}.$$

Verossimilhança

Como temos independência entre indivíduos, a função de verossimilhança será então

$$L(\boldsymbol{\theta}'|\mathbf{y}, \mathbf{X}) \equiv f(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}') = \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Verossimilhança

Como temos independência entre indivíduos, a função de verossimilhança será então

$$L(\boldsymbol{\theta}'|\mathbf{y}, \mathbf{X}) \equiv f(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}') = \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Consideraremos a reparametrização

$$\begin{cases} \tau_j^2 = \sigma_j^2(1 - \delta_j^2); \\ \Delta_j = \sigma_j \delta_j, \end{cases}$$

com $\delta_j = \lambda_j / \sqrt{1 + \lambda_j^2}$.

Verossimilhança

Como temos independência entre indivíduos, a função de verossimilhança será então

$$L(\boldsymbol{\theta}'|\mathbf{y}, \mathbf{X}) \equiv f(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}') = \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Consideraremos a reparametrização

$$\begin{cases} \tau_j^2 = \sigma_j^2(1 - \delta_j^2); \\ \Delta_j = \sigma_j \delta_j, \end{cases}$$

com $\delta_j = \lambda_j / \sqrt{1 + \lambda_j^2}$. Desta forma,

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}) \equiv f(\mathbf{y}|\mathbf{X}, \boldsymbol{\theta}) = \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \tau_j^2 + \Delta_j^2, \Delta_j/\tau_j, \nu).$$

Verossimilhança

O processo inferencial será feito para θ , após isto recuperamos os valores de interesse θ' através da transformação inversa:

$$\begin{cases} \sigma_j^2 = \tau_j^2 + \Delta_j^2; \\ \lambda_j = \Delta_j / \tau_j. \end{cases}$$

Label Switching

O modelo apresenta um problema de identificabilidade conhecido como *Label Switching*.

Label Switching

O modelo apresenta um problema de identificabilidade conhecido como *Label Switching*.

Por exemplo, considere $n = 1$ e $G = 2$,

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}) = p_1 \text{St}(y_1|\mathbf{x}_1^\top \boldsymbol{\beta}_1 + b\Delta_1, \tau_1^2 + \Delta_1^2, \Delta_1/\tau_1, \nu) + p_2 \text{St}(y_1|\mathbf{x}_1^\top \boldsymbol{\beta}_2 + b\Delta_2, \tau_2^2 + \Delta_2^2, \Delta_2/\tau_2, \nu).$$

Label Switching

O modelo apresenta um problema de identificabilidade conhecido como *Label Switching*.

Por exemplo, considere $n = 1$ e $G = 2$,

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}) = p_1 \text{St}(y_1 | \mathbf{x}_1^\top \boldsymbol{\beta}_1 + b\Delta_1, \tau_1^2 + \Delta_1^2, \Delta_1/\tau_1, \nu) + p_2 \text{St}(y_1 | \mathbf{x}_1^\top \boldsymbol{\beta}_2 + b\Delta_2, \tau_2^2 + \Delta_2^2, \Delta_2/\tau_2, \nu).$$

Dada uma permutação κ de $1, 2, \dots, G$ qualquer,

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}) = \prod_{i=1}^n \sum_{j=1}^G p_{\kappa(j)} \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_{\kappa(j)} + b\Delta_{\kappa(j)}, \tau_{\kappa(j)}^2 + \Delta_{\kappa(j)}^2, \Delta_{\kappa(j)}/\tau_{\kappa(j)}, \nu).$$

Label Switching





Figura 2: Cartela de ovo.

Label Switching



10

Dealing with label switching under model uncertainty

Sylvia Frühwirth-Schnatter

10.1 Introduction

This chapter considers identification of a finite mixture distribution with K components,

$$p(\mathbf{y}|\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K, \boldsymbol{\eta}) = \sum_{k=1}^K \eta_k f_{\mathcal{T}}(\mathbf{y}|\boldsymbol{\theta}_k), \quad (10.1)$$

where \mathbf{y} is the realisation of a univariate or multivariate, discrete- or continuous-valued random variable and the component densities $f_{\mathcal{T}}(\mathbf{y}|\boldsymbol{\theta}_k)$ arise from the same distribution family $\mathcal{T}(\boldsymbol{\theta})$ indexed by a parameter $\boldsymbol{\theta}$ taking values in Θ . Given a sample $\mathbf{y} = (\mathbf{y}_1, \dots, \mathbf{y}_N)$, identification of (10.1) concerns estimating K , the component-specific parameters $\boldsymbol{\theta}_1, \dots, \boldsymbol{\theta}_K$ as well as the weight distribution $\boldsymbol{\eta} = (\eta_1, \dots, \eta_K)$. A comprehensive review of finite mixture models and their estimation is provided by the monographs of Titterton *et al.* (1985), McLachlan and Peel (2000) and Frühwirth-Schnatter (2006). This chapter is based on Bayesian inference using MCMC methods, which date back to Diebolt and Robert (1994); see Frühwirth-Schnatter (2006, Chapter 3) and Marin *et al.* (2005) for a review.

Figura 3: Solução para o *Label Switching*.

Distribuições *a priori*

As especificações *a priori* são

- Consideramos o número de componentes G conhecido;
- Independência *a priori* entre p, β, τ^2, Δ e ν ;
- Independência *a priori* entre componentes para os parâmetros específicos de cada componente, β, τ^2 e Δ (por exemplo $\beta_1 \perp \beta_2$).

Distribuições *a priori*

As especificações são as seguintes:

$$\mathbf{p} \sim \text{Dirichlet}(\xi_1, \xi_2, \dots, \xi_G);$$

$$\boldsymbol{\beta}_j \sim N_{k+1}(0, c^2 \mathbb{I}_{k+1});$$

$$\Delta_j \sim N(\eta, \omega^2);$$

$$\tau_j^2 \sim \text{InvGama}(r, s);$$

$$\nu | \alpha \sim \exp(\alpha), \alpha \sim \text{Unif}(0.02, 0.5),$$

em que k é o número de covariáveis que compõem \mathbf{X} e \mathbb{I}_{k+1} denota a matriz identidade de ordem $k + 1$.

Distribuições *a priori*

The screenshot shows the top section of a journal article page. At the top left is the journal logo and name: "Journal of Applied Statistics > Volume 42, 2015 - Issue 12". To the right is a search bar with the placeholder text "Enter keywords, authors, DOI, etc". Below the journal name are two buttons: "Submit an article" (green) and "journal homepage" (dark blue). On the left side, there are statistics: "545 Views", "17 CrossRef citations to date", and "0 Altmetric". The main title of the article is "Bayesian analysis of censored linear regression models with scale mixtures of normal distributions". Below the title are the authors: "Aldo M. Garay, Heleno Bolfarine, Victor H. Lachos & Celso R.B. Cabral". Below the authors is the page information: "Pages 2694-2714 | Received 17 Sep 2013, Accepted 04 May 2015, Published online: 09 Aug 2015". Below the page information are two links: "Cite this article" and "https://doi.org/10.1080/02664763.2015.1048671". Below the links is a "Check for updates" button. At the bottom of the article section are several buttons: "Full Article" (dark blue), "Figures & data" (light blue), "References" (light blue), "Citations" (light blue), "Metrics" (light blue), "Reprints & Permissions" (light blue), and "Read this article" (green).

Journal of Applied Statistics >
Volume 42, 2015 - Issue 12

Submit an article journal homepage

545 Views
17 CrossRef citations to date
0 Altmetric

Original Articles

Bayesian analysis of censored linear regression models with scale mixtures of normal distributions

Aldo M. Garay, Heleno Bolfarine, Victor H. Lachos & Celso R.B. Cabral

Pages 2694-2714 | Received 17 Sep 2013, Accepted 04 May 2015, Published online: 09 Aug 2015

Cite this article <https://doi.org/10.1080/02664763.2015.1048671> Check for updates

Full Article Figures & data References Citations Metrics Reprints & Permissions Read this article

Abstract


Related

Figura 4: Motivação para a *a priori* de ν

Distribuições *a priori*

A *priori* para θ terá a seguinte estrutura:

$$\begin{aligned}\pi(\theta) &= \pi(\mathbf{p}, \boldsymbol{\beta}, \boldsymbol{\tau}^2, \boldsymbol{\Delta}, \nu, \alpha) \\ &= \pi(\mathbf{p})\pi(\boldsymbol{\beta})\pi(\boldsymbol{\tau}^2)\pi(\boldsymbol{\Delta})\pi(\nu, \alpha) \\ &= \pi(\mathbf{p})\pi(\nu|\alpha)\pi(\alpha) \prod_{j=1}^G \pi(\boldsymbol{\beta}_j)\pi(\boldsymbol{\tau}_j^2)\pi(\boldsymbol{\Delta}_j).\end{aligned}$$



Estimação, ajuste e seleção de modelos

Distribuição a *posteriori*

Em uma abordagem Bayesiana, o objeto principal é a distribuição a *posteriori*, que neste modelo deve ser tal que:

$$\begin{aligned}\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}) &\propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X})\pi(\boldsymbol{\theta}) \\ &= \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \tau_j^2 + \Delta_j^2, \Delta_j/\tau_j, \nu) \\ &\quad \times \pi(\mathbf{p})\pi(\nu|\alpha)\pi(\alpha) \prod_{j=1}^G \pi(\boldsymbol{\beta}_j)\pi(\tau_j^2)\pi(\Delta_j).\end{aligned}$$

O que fazer?

O que fazer?

- Consideraremos que são observadas as variáveis Z , T e U mostradas na representação hierárquica.

O que fazer?

- Consideraremos que são observadas as variáveis Z , T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i | 0, u_i^{-1}) \text{Gm}(u_i | \nu/2, \nu/2)]. \mathbf{1}(Z_i=j)$$

O que fazer?

- Consideraremos que são observadas as variáveis Z, T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i|\mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i|0, u_i^{-1}) \text{Gm}(u_i|\nu/2, \nu/2)].^{1(Z_i=j)}$$

- Desejamos então encontrar $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})\pi(\boldsymbol{\theta})$;

O que fazer?

- Consideraremos que são observadas as variáveis Z, T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i | 0, u_i^{-1}) \text{Gm}(u_i | \nu/2, \nu/2)]^{\mathbf{1}(Z_i=j)}$$

- Desejamos então encontrar $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})\pi(\boldsymbol{\theta})$;
- É possível encontrar as condicionais completas de $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})$;

O que fazer?

- Consideraremos que são observadas as variáveis Z, T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i|\mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i|0, u_i^{-1}) \text{Gm}(u_i|\nu/2, \nu/2)]. \mathbf{1}(Z_i=j)$$

- Desejamos então encontrar $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})\pi(\boldsymbol{\theta})$;
- É possível encontrar as condicionais completas de $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})$;
- Utilizaremos o algoritmo *Gibbs sampler*, para obtermos amostras da distribuição *a posteriori*;

O que fazer?

- Consideraremos que são observadas as variáveis Z, T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i|\mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i|0, u_i^{-1}) \text{Gm}(u_i|\nu/2, \nu/2)] \cdot \mathbf{1}(Z_i=j)$$

- Desejamos então encontrar $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \pi(\boldsymbol{\theta})$;
- É possível encontrar as condicionais completas de $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})$;
- Utilizaremos o algoritmo *Gibbs sampler*, para obtermos amostras da distribuição *a posteriori*;
- Com o *Gibbs sampler* construímos uma Cadeia de Markov cuja distribuição estacionária é a *posteriori*;

O que fazer?

- Consideraremos que são observadas as variáveis Z, T e U mostradas na representação hierárquica.

$$L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) = \prod_{j=1}^G p_j^{m_j} \prod_{i=1}^n [\phi(y_i|\mathbf{x}_i^\top \boldsymbol{\beta}_j + \Delta_j(b+t_i), u_i^{-1} \tau_j^2) \text{Nt}(t_i|0, u_i^{-1}) \text{Gm}(u_i|\nu/2, \nu/2)]. \mathbf{1}(Z_i=j)$$

- Desejamos então encontrar $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u}) \propto L(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})\pi(\boldsymbol{\theta})$;
- É possível encontrar as condicionais completas de $\pi(\boldsymbol{\theta}|\mathbf{y}, \mathbf{X}, \mathbf{z}, \mathbf{t}, \mathbf{u})$;
- Utilizaremos o algoritmo *Gibbs sampler*, para obtermos amostras da distribuição *a posteriori*;
- Com o *Gibbs sampler* construímos uma Cadeia de Markov cuja distribuição estacionária é a *posteriori*;
- Quantidades de interesse são calculadas com base na cadeia obtida, técnica denominada MCMC.

Condicionais completas

São as distribuições de um parâmetro do modelo dados os demais parâmetros e a amostra, por exemplo, a condicional completa de β_1 é $\beta_1 | \beta_{-1}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \mathbf{u}, \dots$

Condicionais completas

São as distribuições de um parâmetro do modelo dados os demais parâmetros e a amostra, por exemplo, a condicional completa de β_1 é $\beta_1|\beta_{-1}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \mathbf{u}, \dots$

$$p|\mathbf{y}, \mathbf{z}, \dots \sim \text{Dirichlet}(\xi_1 + m_1, \xi_2 + m_2, \dots, \xi_G + m_G)$$

$$\beta_j|\beta_{-j}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \mathbf{u}, \dots \sim N_k(\Sigma_j^{-1}\mathbf{w}_j, \tau_j^2\Sigma_j^{-1})$$

$$\tau_j^2|\tau_{-j}^2, \mathbf{y}, \mathbf{z}, \mathbf{t}, \mathbf{u}, \dots \sim \text{InvGama}\left(\frac{m_j}{2} + r, \frac{S_3 + s}{2}\right)$$

$$\Delta_j|\Delta_{-j}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \mathbf{u}, \dots \sim N\left(\frac{\omega S_1 + \eta\tau_j^2}{\omega S_2 + \tau_j^2}, \frac{\omega^2\tau_j^2}{\omega S_2 + \tau_j^2}\right)$$

$$\alpha|\mathbf{y}, \dots \sim \text{Gama}_{(0.02, 0.5)}(2, \nu),$$

$$\mathbb{P}(Z_i = j|\mathbf{z}_{-i}, \mathbf{y}, \dots) \propto p_j \text{St}(y_i|\mathbf{x}_i^\top \beta_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu)$$

Condicionais completas

$$t_i | \mathbf{t}_{-i}, \mathbf{y}, \mathbf{z}, \mathbf{u}, \dots \sim N_{(0, \infty)} \left(\frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j - b \Delta_j) \Delta_j}{\Delta_j^2 + \tau_j^2}, \frac{\tau_j^2}{u_i(\Delta_j^2 + \tau_j^2)} \right),$$

$$u_i | \mathbf{u}_{-i}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \dots \sim \text{Gama} \left(\frac{\nu}{2} + 1, \frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j - (b + t_i) \Delta_j)^2}{2\tau_j^2} + \frac{t_i^2 + \nu}{2} \right)$$

Condicionais completas

$$t_i | \mathbf{t}_{-i}, \mathbf{y}, \mathbf{z}, \mathbf{u}, \dots \sim N_{(0, \infty)} \left(\frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j - b \Delta_j) \Delta_j}{\Delta_j^2 + \tau_j^2}, \frac{\tau_j^2}{u_i(\Delta_j^2 + \tau_j^2)} \right),$$
$$u_i | \mathbf{u}_{-i}, \mathbf{y}, \mathbf{z}, \mathbf{t}, \dots \sim \text{Gama} \left(\frac{\nu}{2} + 1, \frac{(y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j - (b + t_i) \Delta_j)^2}{2\tau_j^2} + \frac{t_i^2 + \nu}{2} \right)$$

Definindo $\mathbf{w}_j = \mathbf{X}_j^\top \mathbf{U}_j (\mathbf{y}_j - (b + \mathbf{t}_j) \Delta_j)$ e $\Sigma_j = \mathbf{X}_j^\top \mathbf{U}_j \mathbf{X}_j + \tau_j^2 c^{-2} \mathbb{I}_{k+1}$, com $\mathbf{U}_j = \text{diag}(\mathbf{u}_j)$, \mathbf{X}_j como a matriz composta das i -ésimas linhas de \mathbf{X} tais que $z_i = j$, $\mathbf{y}_j, \mathbf{t}_j, \mathbf{u}_j$ denotando o vetor composto pelos i -ésimos elementos dos respectivos vetores $\mathbf{y}, \mathbf{t}, \mathbf{u}$ tais que $z_i = j$,

- $S_1 = \sum_{I_j} u_i (y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j) (b + t_i)$;
- $S_2 = \sum_{I_j} u_i (b + t_i)^2$;
- $S_3 = \sum_{I_j} u_i (y_i - \mathbf{x}_i^\top \boldsymbol{\beta}_j - (b + t_i) \Delta_j)^2$, com $I_j = \{i | z_i = j\}$.

Condicionais completas

A exceção é condicional completa de ν , cuja densidade é

$$\pi(\nu|\mathbf{y}, \dots) \propto e^{-\alpha\nu} \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Que não é o núcleo de uma distribuição conhecida, utilizaremos o algoritmo de Metropolis-Hastings nesse passo.

Condicionais completas

A exceção é condicional completa de ν , cuja densidade é

$$\pi(\nu|\mathbf{y}, \dots) \propto e^{-\alpha\nu} \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Que não é o núcleo de uma distribuição conhecida, utilizaremos o algoritmo de Metropolis-Hastings nesse passo.

1. Geramos uma observação proposta $\nu^* \sim \text{LN}(\log(\nu^{(q-1)}), \phi_\nu^2)$;

Condicionais completas

A exceção é condicional completa de ν , cuja densidade é

$$\pi(\nu|\mathbf{y}, \dots) \propto e^{-\alpha\nu} \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Que não é o núcleo de uma distribuição conhecida, utilizaremos o algoritmo de Metropolis-Hastings nesse passo.

1. Geramos uma observação proposta $\nu^* \sim \text{LN}(\log(\nu^{(q-1)}), \phi_\nu^2)$;
2. Calculamos $\text{aceit}(\nu^{(q-1)}, \nu^*) = \min \left\{ 1, \frac{\pi(\nu^*|\mathbf{y}, \dots) \nu^*}{\pi(\nu^{(q-1)}|\mathbf{y}, \dots) \nu^{(q-1)}} \right\}$;

Condicionais completas

A exceção é condicional completa de ν , cuja densidade é

$$\pi(\nu|\mathbf{y}, \dots) \propto e^{-\alpha\nu} \prod_{i=1}^n \sum_{j=1}^G p_j \text{St}(y_i | \mathbf{x}_i^\top \boldsymbol{\beta}_j + b\Delta_j, \sigma_j^2, \lambda_j, \nu).$$

Que não é o núcleo de uma distribuição conhecida, utilizaremos o algoritmo de Metropolis-Hastings nesse passo.

1. Geramos uma observação proposta $\nu^* \sim \text{LN}(\log(\nu^{(q-1)}), \phi_\nu^2)$;
2. Calculamos $\text{aceit}(\nu^{(q-1)}, \nu^*) = \min \left\{ 1, \frac{\pi(\nu^*|\mathbf{y}, \dots)\nu^*}{\pi(\nu^{(q-1)}|\mathbf{y}, \dots)\nu^{(q-1)}} \right\}$;
3. Com probabilidade $\text{aceit}(\nu^{(q-1)}, \nu^*)$, fazemos $\nu^{(q)} = \nu^*$, caso contrário $\nu^{(q)} = \nu^{(q-1)}$.

Solucionando *Label Switching*

- Obtemos as amostras;

Solucionando *Label Switching*

- Obtemos as amostras;
- Descartamos uma certa quantidade de forma a obter convergência, ficamos com Q amostras;

Solucionando *Label Switching*

- Obtemos as amostras;
- Descartamos uma certa quantidade de forma a obter convergência, ficamos com Q amostras;

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} \\ \Delta_1^{(2)} & \Delta_2^{(2)} \\ \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}.$$

Solucionando *Label Switching*

- Obtemos as amostras;
- Descartamos uma certa quantidade de forma a obter convergência, ficamos com Q amostras;

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} \\ \Delta_1^{(2)} & \Delta_2^{(2)} \\ \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}.$$

A solução proposta por Frühwirth-Schnatter (2011) é:

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} & \Delta_1^{(2)} & \Delta_2^{(2)} & \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}$$

Solucionando *Label Switching*

- Obtemos as amostras;
- Descartamos uma certa quantidade de forma a obter convergência, ficamos com Q amostras;

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} \\ \Delta_1^{(2)} & \Delta_2^{(2)} \\ \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}.$$

A solução proposta por Frühwirth-Schnatter (2011) é:

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} & \Delta_1^{(2)} & \Delta_2^{(2)} & \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix} \xrightarrow{k-means} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 1 & 2 \end{bmatrix}$$

Solucionando *Label Switching*

- Obtemos as amostras;
- Descartamos uma certa quantidade de forma a obter convergência, ficamos com Q amostras;

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} \\ \Delta_1^{(2)} & \Delta_2^{(2)} \\ \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}.$$

A solução proposta por Frühwirth-Schnatter (2011) é:

$$\begin{bmatrix} \Delta_1^{(1)} & \Delta_2^{(1)} & \Delta_1^{(2)} & \Delta_2^{(2)} & \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix} \xrightarrow{k-means} \begin{bmatrix} 1 & 1 \\ 2 & 1 \\ 1 & 2 \end{bmatrix} \rightarrow \begin{bmatrix} \Delta_2^{(2)} & \Delta_1^{(2)} \\ \Delta_1^{(3)} & \Delta_2^{(3)} \end{bmatrix}$$

Solucionando *Label Switching*

- Ao final do processo temos Q_κ amostras;

Solucionando *Label Switching*

- Ao final do processo temos Q_κ amostras;
- Uma baixa fração Q_κ/Q indica que o número G fixado sobrestima o número de componentes que gerou os dados;

Solucionando *Label Switching*

- Ao final do processo temos Q_κ amostras;
- Uma baixa fração Q_κ/Q indica que o número G fixado sobrestima o número de componentes que gerou os dados;
- Uma desvantagem deste método é que perdemos o controle sobre o número de amostras geradas.

Seleção de modelos

- Foi escolhido o critério de informação WAIC;

Seleção de modelos

- Foi escolhido o critério de informação WAIC;
- É invariante ao *Label Switching*, podendo ser calculado com as amostras sem a correção.

Seleção de modelos

- Foi escolhido o critério de informação WAIC;
- É invariante ao *Label Switching*, podendo ser calculado com as amostras sem a correção.


$$\text{WAIC} = -\frac{4}{Q} \sum_{q=1}^Q \sum_{i=1}^n \log f(y_i | \boldsymbol{\theta}^{(q)}) + 2 \sum_{i=1}^n \log \left(\frac{1}{Q} \sum_{q=1}^Q f(y_i | \boldsymbol{\theta}^{(q)}) \right).$$

Análise de resíduos

- Utilizamos os resíduos quantílicos, que possuem distribuição normal caso o modelo esteja bem especificado;

Análise de resíduos

- Utilizamos os resíduos quantílicos, que possuem distribuição normal caso o modelo esteja bem especificado;
- Podemos obter uma amostra dos resíduos quantílicos utilizando as amostras sem a correção de *Label Switching*.



Gerando dados

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;
- Considerados 3 tipos de dados:

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;
- Considerados 3 tipos de dados:
 1. Balanceados com componentes separadas;

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;
- Considerados 3 tipos de dados:
 1. Balanceados com componentes separadas;
 2. Desbalanceados com componentes separadas;

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;
- Considerados 3 tipos de dados:
 1. Balanceados com componentes separadas;
 2. Desbalanceados com componentes separadas;
 3. Desbalanceados com componentes próximas.

Gerando dados

- Simulados utilizando a representação hierárquica do modelo fixando $G = 3$;
- Considerados 3 tipos de dados:
 1. Balanceados com componentes separadas;
 2. Desbalanceados com componentes separadas;
 3. Desbalanceados com componentes próximas.
- Dois tamanhos amostrais $n = 100$ e $n = 1000$;
- Matriz modelo X : uns na primeira coluna e a segunda n amostras de uma normal padrão.

Gerando dados

- Parâmetros comuns entre os tipos de dados:

$$\sigma^2 = \begin{bmatrix} 1 & 4 & 9 \end{bmatrix}^\top, \quad \lambda = \begin{bmatrix} 10 & -8 & -8 \end{bmatrix}^\top \quad \text{e} \quad \nu = 3;$$

Gerando dados

- Parâmetros comuns entre os tipos de dados:

$$\sigma^2 = \begin{bmatrix} 1 & 4 & 9 \end{bmatrix}^\top, \quad \lambda = \begin{bmatrix} 10 & -8 & -8 \end{bmatrix}^\top \quad \text{e} \quad \nu = 3;$$

- Parâmetros exclusivos:

- Tipo 1:

$$\mathbf{p} = \begin{bmatrix} 0,3 & 0,4 & 0,3 \end{bmatrix}^\top, \quad \boldsymbol{\beta} = \begin{bmatrix} 30 & 15 & -30 \\ 4 & 4 & -4 \end{bmatrix}$$

- Tipo 2:

$$\mathbf{p} = \begin{bmatrix} 0,05 & 0,15 & 0,8 \end{bmatrix}^\top, \quad \boldsymbol{\beta} = \begin{bmatrix} 30 & 15 & -30 \\ 4 & 4 & -4 \end{bmatrix}$$

- Tipo 3:

$$\mathbf{p} = \begin{bmatrix} 0,8 & 0,15 & 0,05 \end{bmatrix}^\top, \quad \boldsymbol{\beta} = \begin{bmatrix} 0 & -10 & -25 \\ 4 & -5 & -4 \end{bmatrix}$$

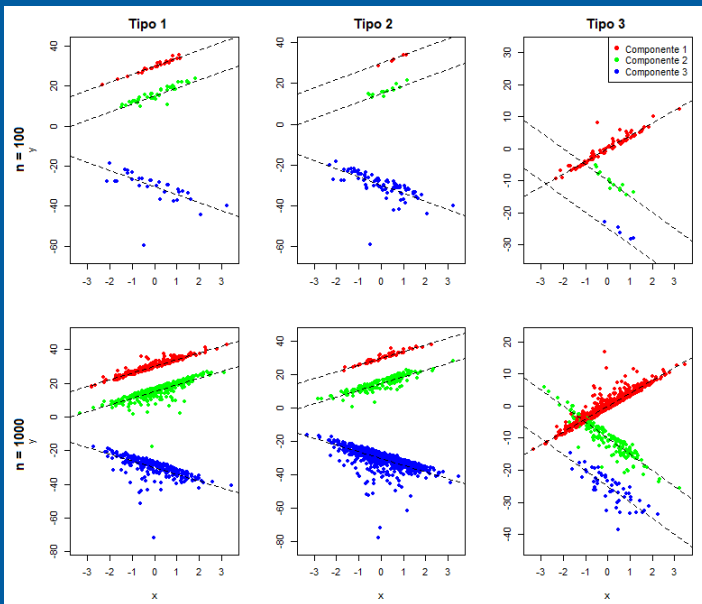


Figura 5: Conjuntos de dados simulados.

Ajuste

- O modelo foi ajustado em cada conjunto de dados fixando $G = 2, 3, 4$;

Ajuste

- O modelo foi ajustado em cada conjunto de dados fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

$$\xi_1 = \xi_2 = \cdots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

Ajuste

- O modelo foi ajustado em cada conjunto de dados fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

$$\xi_1 = \xi_2 = \dots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

- Com o *Gibbs sampler* obtivemos $Q = 5.000$ amostras após os descartes;

Ajuste

- O modelo foi ajustado em cada conjunto de dados fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

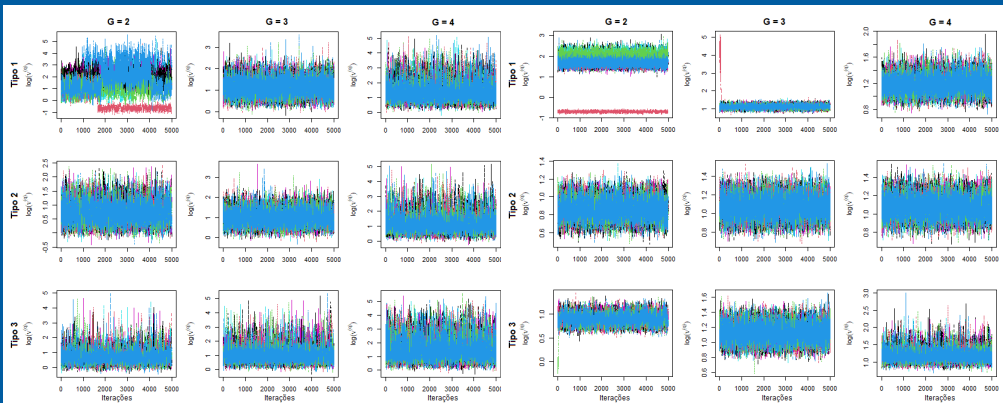
$$\xi_1 = \xi_2 = \dots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

- Com o *Gibbs sampler* obtivemos $Q = 5.000$ amostras após os descartes;
- O procedimento foi replicado 10 vezes.



(a) $n = 100$

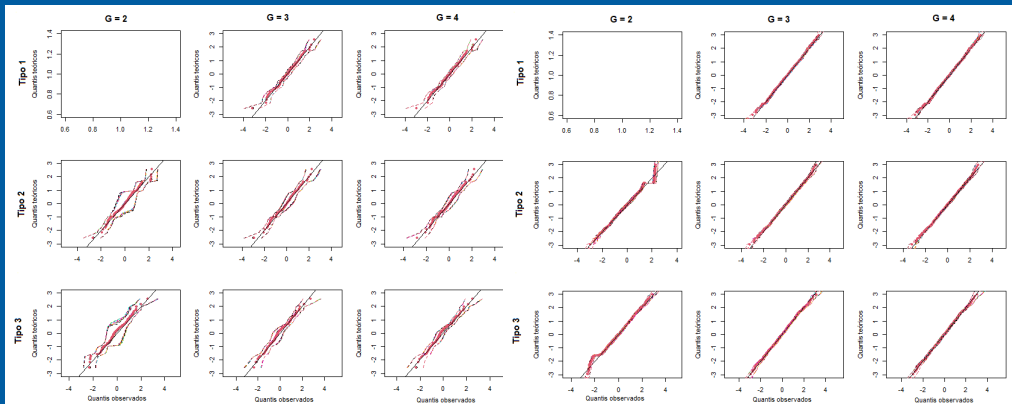
(b) $n = 1000$

Figura 6: Logaritmo natural das amostras da *posteriori* de ν ao longo das iterações do GS considerando os 3 tipos de dados e número de componentes, para $n = 100$ e $n = 1000$.

Tipo	n	$G = 2$			$G = 3$		
		Taxa	WAIC2/WAIC3	WAIC2/WAIC4	Taxa	WAIC3/WAIC2	WAIC3/WAIC4
1	100	-	-	-	0,9937	-	0,1
	1000	-	-	-	1	-	1
2	100	0,9982	0	0	0,1018	1	0,4
	1000	1	0	0	0,9495	1	0,9
3	100	0,9872	0	0	0,5953	1	0
	1000	1	0	0	0,6539	1	1

Tipo	n	$G = 4$		
		Taxa	WAIC4/WAIC2	WAIC4/WAIC3
1	100	0,1391	-	0,9
	1000	0,1319	-	0
2	100	0,0200	1	0,6
	1000	0,1001	1	0,1
3	100	0,1087	1	1
	1000	0,0957	1	0

Tabela 1: Taxa média de permutações válidas e critério de seleção de modelos para os dados simulados.



(a) $n = 100$

(b) $n = 1000$

Figura 7: Gráfico quantil-quantil dos resíduos quantílicos considerando diversos números de componentes, com $n = 100$ e $n = 1000$ para cada réplica.

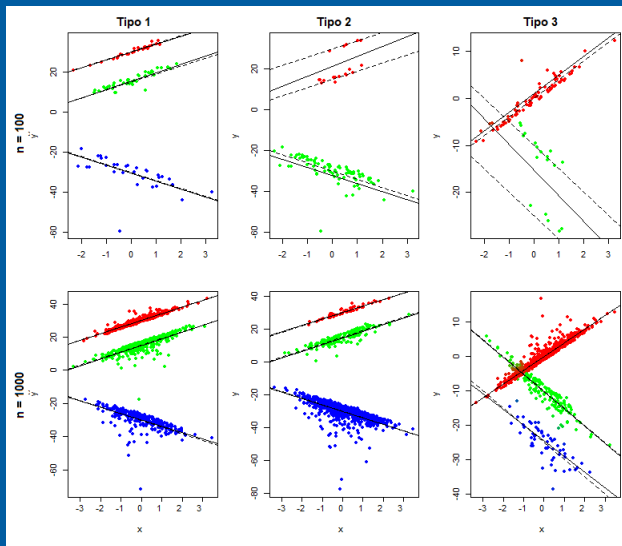


Figura 8: Resultado de classificação e retas de regressão.




Figura 9: Resultado de classificação e retas de regressão.

Tipo	n	σ_1^2	σ_2^2	σ_3^2	λ_1	λ_2	λ_3	ν
1	100	0,5788	2,8488	15,9764	2,4419	-4,2165	-11,8060	3,3156
	1000	1,3424	4,5225	8,7590	9,1936	-10,7483	-7,1787	3,0757
2	100	158,0027	35,5182	-	9,2582	-6,2435	-	2,1873
	1000	1,1787	5,0340	9,5194	4,7982	-7,6128	-8,8242	2,9235
3	100	2,3204	22,0667	-	4,9606	-6,7849	-	2,1900
	1000	1,0772	4,8147	7,8710	9,2715	-5,2249	-0,3573	3,0855
Fixado		1	4	9	10	-8	-8	3

Tabela 2: Estimativas pela média *a posteriori* para os dados simulados.



Percepção de tons

Dados

- Disponíveis no R pelo pacote `mixtools`;

Dados

- Disponíveis no R pelo pacote `mixtools`;
- Uma frequência fundamental e um sobretom desta frequência foram tocados para um músico treinado;

Dados

- Disponíveis no R pelo pacote `mixtools`;
- Uma frequência fundamental e um sobretom desta frequência foram tocados para um músico treinado;
- O músico então era instruído a “afinar” o sobretom para a oitava acima da frequência fundamental;

Dados

- Disponíveis no R pelo pacote `mixtools`;
- Uma frequência fundamental e um sobretom desta frequência foram tocados para um músico treinado;
- O músico então era instruído a “afinar” o sobretom para a oitava acima da frequência fundamental;
- Os dados são compostos por 150 replicações deste experimento com o mesmo músico;

Dados

- Disponíveis no R pelo pacote `mixtools`;
- Uma frequência fundamental e um sobretom desta frequência foram tocados para um músico treinado;
- O músico então era instruído a “afinar” o sobretom para a oitava acima da frequência fundamental;
- Os dados são compostos por 150 replicações deste experimento com o mesmo músico;
- Anteriormente analisados por Sabillón et al. (2023) utilizando um modelo de misturas de regressões normais.




Figura 10: Diagrama de dispersão para os dados do estudo de percepção de tons.

Ajuste

- O modelo foi ajustado fixando $G = 2, 3, 4$;

Ajuste

- O modelo foi ajustado fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

$$\xi_1 = \xi_2 = \cdots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

Ajuste

- O modelo foi ajustado fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

$$\xi_1 = \xi_2 = \dots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

- Com o *Gibbs sampler* obtivemos $Q = 5.000$ amostras após os descartes;

Ajuste

- O modelo foi ajustado fixando $G = 2, 3, 4$;
- Fixamos os hiperparâmetros em:

$$\xi_1 = \xi_2 = \dots = \xi_G = 1$$

$$c = 10$$

$$\eta = 0; \omega = 10$$

$$r = s = 0, 1.$$

- Com o *Gibbs sampler* obtivemos $Q = 5.000$ amostras após os descartes;
- O procedimento foi replicado 10 vezes.

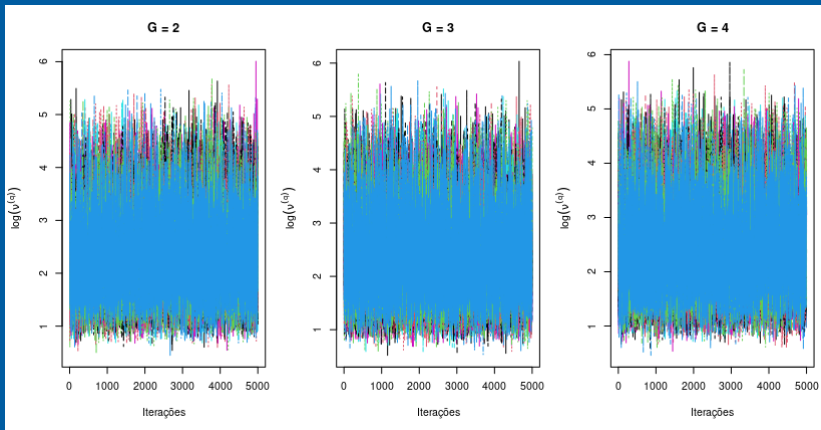


Figura 11: Logaritmo natural das amostras da *posteriori* de ν ao longo das iterações do GS para os dados do estudo de percepção de tons, considerando $G = 2, 3$ e 4.

Nº Componentes	Taxa	WAIC2/WAIC3	WAIC2/WAIC4	WAIC3/WAIC4
2	1	1	1	-
3	0,1204	-	-	1
4	0,0161	-	-	-

Tabela 3: Taxa média de permutações válidas e proporção de vezes que o WAIC de um modelo é menor que o WAIC de outro modelo dentre as replicações.




Figura 12: Gráfico quantil-quantil para os dados do estudo de percepção de tons, em cada replicação.




Figura 13: Valor da variável resposta por ordem de coleta.





Figura 14: Resultados de classificação e retas de regressão estimadas para os dados do experimento de percepção de tons.



(c) DDRJ

Figura 15: Resultados de classificação de Sabillón et al. (2023).

Considerações finais

- Do estudo de simulação:

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:
 - Classificação similar a Sabillón et al. (2023);

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:
 - Classificação similar a Sabillón et al. (2023);
 - O modelo não é adequado;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:
 - Classificação similar a Sabillón et al. (2023);
 - O modelo não é adequado;
- Futuramente:
 - Simulação com mais conjuntos de dados para verificar o vício dos estimadores;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:
 - Classificação similar a Sabillón et al. (2023);
 - O modelo não é adequado;
- Futuramente:
 - Simulação com mais conjuntos de dados para verificar o vício dos estimadores;
 - Obter outros conjuntos de dados;

Considerações finais

- Do estudo de simulação:
 - O modelo é capaz de recuperar o valor dos parâmetros fixados de forma consistente quando $n = 1000$;
 - O tamanho amostral influencia na determinação do número de componentes;
 - A taxa de permutações válidas indica de forma mais precisa a sobrestimação do número de componentes;
- Do estudo de percepção de tons:
 - Classificação similar a Sabillón et al. (2023);
 - O modelo não é adequado;
- Futuramente:
 - Simulação com mais conjuntos de dados para verificar o vício dos estimadores;
 - Obter outros conjuntos de dados;
 - Estimação do número de componentes em conjunto dos parâmetros.

Referências I

- Azzalini, A. (1985). "A class of distributions which includes the normal ones." *Scandinavian Journal of Statistics*, 12, 171–178.
- Frühwirth-Schnatter, S. (2011). "Dealing with label switching under model uncertainty." *Mixtures: estimation and applications*, 213–239.
- Sabillón, G. A., Cotrim, L. G. F., e Zuanetti, D. A. (2023). "A data-driven reversible jump for estimating a finite mixture of regression models." *TEST*, 32, 1, 350–369.

Obrigado.



github.com/Bola382/Stochastic